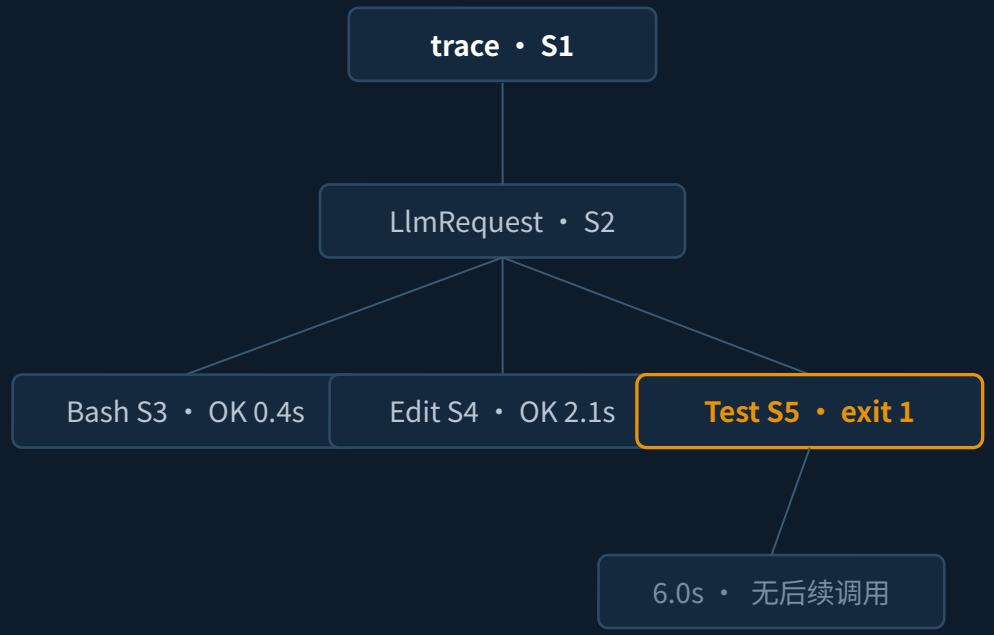
小组分享 · agent-trace 优化方向 · 记忆篇

记忆，是 trace 最挑剔的下游

从 74 篇记忆生成调研，反看 agent-trace 该补什么



统一逻辑树：每个节点有编号、状态、耗时——可被引用

检索截至 2026-10-09 · 约 25 分钟 + 自由讨论

为什么从‘记忆’看 trace?

目的 让 agent 的行为可观测、可回放、可被上层应用消费。

家底 多源对话已能归一成统一 span 树 (trace-synthesis) 。

底座该长成什么样 , 不该我们拍脑袋——记忆系统想把一次性的轨迹变成可复用的知识 , 它同时要四样东西 :

内容 消息、工具输入输出、报错全文——读了什么

结构 父子 span 、边界、嵌套归属——谁调用了谁

信号 执行侧结果 , 而不是模型嘴上的自述——到底成了没

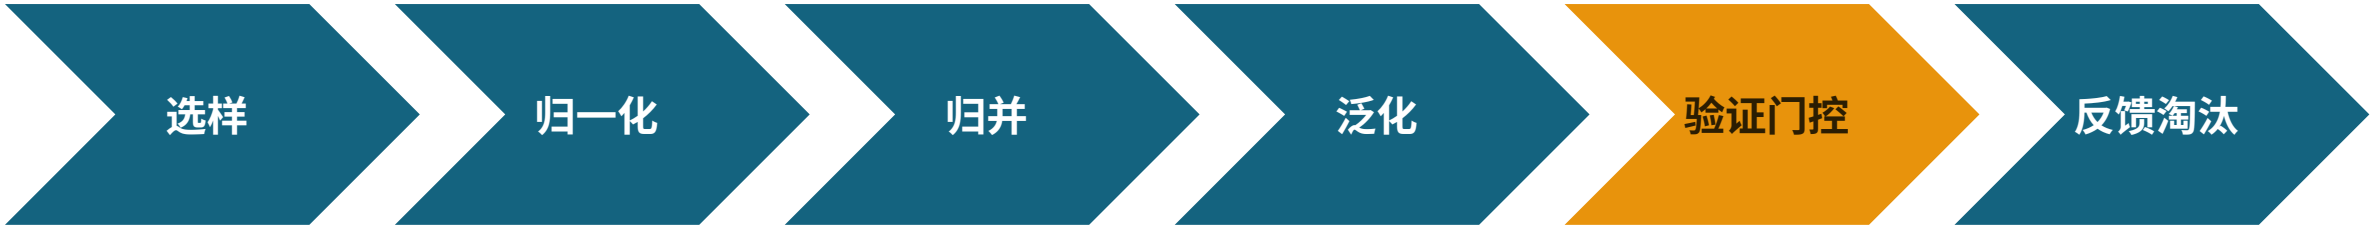
来源 每条结论都能回指到源 span—— 这话谁说的

看下游缺什么 ,
就是看 trace 该补什么。

本次路线 :
全景 → 三条铁律 → 空白与机会 → 最小实验 → 讨论

七条路，汇成同一条漏斗

过程挖掘 · AIOps · 提示优化 · 参数化记忆 · Agent Skills · 软件工程 · 查询日志挖掘——七个互不相识的领域，独立收敛出同一条流水线



挑值得学的轨迹

统一成一种格式

去重、合并同类

抽成可复用规则

不合格不让进

用得差的清出去

像淘金：大量泥沙 (trace) 层层筛选，留下金粒（可复用的记忆）。
74 项研究 +24 个开源组件，都站在这条漏斗的某一环上；橘色的‘验证门控’是今天故事的关键环。

来源：方法报告 §8（综合）;74 项研究、 24 个开源组件，检索截至 2026-10-09

漏斗要什么 ,trace 就该记什么

漏斗环节	它需要 trace 提供	现状与缺口
选样	可信的成败结果、同任务配对	**✗ 自述不可信 (下一页)**
归一化	统一逻辑树、稳定 span ID	**✓ 我们的主场**
归并	跨 trace 的对齐锚点	**△ 依赖 ID 与结构保真**
验证门控	记忆引用能回指到源轨迹	**✗ 压平之后回不去**
反馈淘汰	记忆使用效果回流	**△ 需要记忆侧埋点**

两个硬缺口——选样 (最前) 与验证门控 (中间)—— 都压在 trace 身上。

来源 : 方法报告 §4/§8; 信号报告 §4-§5

铁律一：模型说‘我成了’，别信

47.6%

失败轨迹中，措辞像‘成功’的
正则口径 :successfully / resolved / fixed

39.2%

真正成功轨迹中，措辞像‘成功’的
同一口径

1,800 条样本、 623 条带标签。两个数字几乎无差别——自述对成败没有区分力，失败的自称成功反而更多。

归因也一样烂
步骤级自动归因命中率 3.5–8.8%，与随机基线 4.2% 同一水平。

产品界已经认账
Codex 把‘自述成功’标为 uncertain;altk-evolve 文档写明“Self-reported success is not evidence”。

唯一可靠的在执行侧
exit code、测试结果、 diff、用户确认—— trace 里要能查到。

所以 trace 必须记执行侧结果——只记模型自述，下游没法用。

来源：信号报告 §5（自述与归因）;Codex v2、 altk-evolve 产品文档

铁律二：攒一批再提炼，别边跑边学

批量：分组一次性归纳

65.83% · 3 分钟

128 路并行抽取 + 层次合并 (Trace2Skill)

流式：逐条读取、反复合并

61.83% · 60 分钟

且各流式方案普遍再低 17–38 个百分点

耗时对比



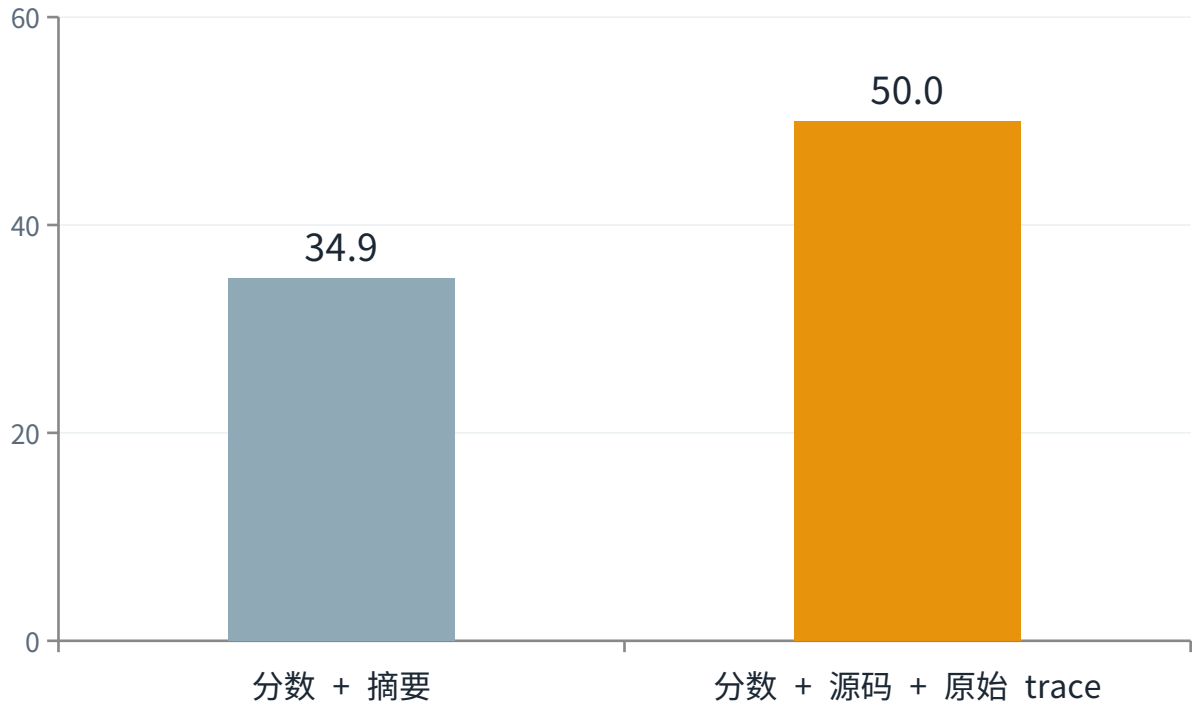
准确率差 4 个百分点，耗时差 20 倍——批处理又快又好。

含义：记忆管道可以纯离线。不必追实时，基建压力小得多。

来源：Trace2Skill(arXiv 2605.12978); 流式 – 17~38pp 综自方法报告 §4

铁律三：值钱的是喂进去的信息

同一模型，只换输入 (Meta-Harness 消融)



只改输入，不改模型

Letta: 同一模型，读轨迹 +9 、再加验证反馈 +15.7 。

强模型不读轨迹也白搭

技能生成 :Claude skill-creator 23.33 vs Qwen 自演化 48.63 。

摘要几乎不加分

仅分数 34.6 → 加摘要 34.9; 加源码与原始 trace 才到 50.0 。

上游压掉的每个字段，都是下游收益的上限——保真是一种投资。

来源：方法报告 §4.8.7;Meta-Harness / Letta / Trace2Skill 消融

两扇“门”：拦上下文 vs 拦权重

门 A · 写入门（笔记本的门）

一条候选记忆，能不能写进记忆库？



污染对象：
上下文——每次检索都会带出来

门 B · 训练门（以 EDGE 为代表）

这条轨迹的训练信号，要不要计入 loss?



污染对象：
权重——练进去就取不出来

都叫 gate，拦的东西完全不同；拦错的代价，都是长期污染。

来源：方法报告 §4.4(EDGE 与记忆 + 训练耦合)

记忆会‘自我膨胀’

0.28 → 0.42

被信任的记忆里，实际是错的比例

静态抽取 0.28 → 闭环自评后 0.42，放大约 1.6 倍（BIRD 1,534 题实测）

记忆自己给自己打分，错的越被信任越留得下来——像滚雪球。

换裁判救不了

换模型、换厂商复核，误差与原自评同源相关（+0.31~0.36）。“换模型不能替代换信号”。

写入太松更糟

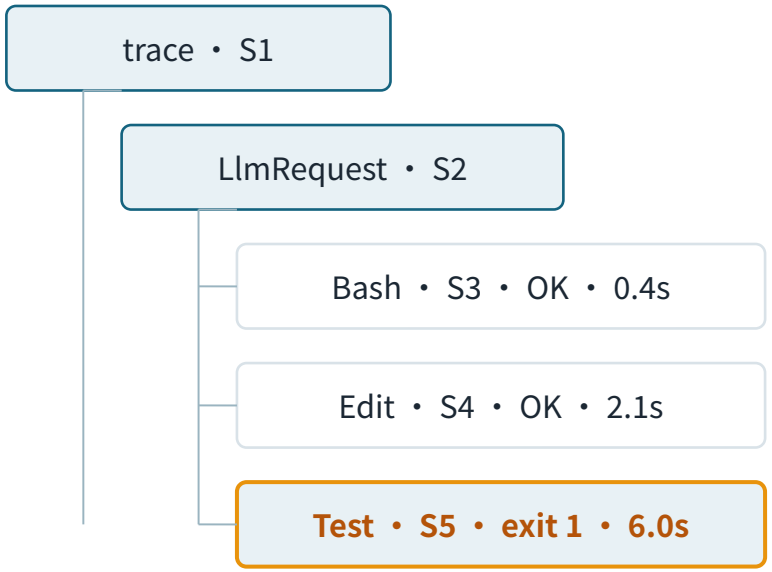
PASB：用户随口一句被写成偏好，写入组后续失败率 71.9% vs 未写入 45.0%（1,600 任务 · 12 模型）。

可靠的验证信号只有两个出处：执行侧结果 + 能回指原文的引用。

来源：arXiv 2608.00017（记忆自评膨胀）；PASB（一次性主张写成偏好）

空白 · 77 个样本

最扎眼的空白：所有人都在“压平”



有编号、有状态、有耗时——每个节点可被引用

压平

单向 · 不可逆



结构、状态、耗时——全部丢失

74 项研究 · 0 篇以 span 树为输入

24 个开源组件 · 全部先压平成文本

最接近的 DENSE · 用的是自建子任务树

来源：方法报告 §5(24 个开源实现)、§4.5(DENSE);altk-evolve 为唯一直接读 OTel span 者，亦只取消息文本

空白 · 两轴拆分

把空白拆成两半：内容轴 vs 形式轴

内容轴

压平丢掉的那些信息，有害吗？

有间接证据

- WISE-Flow: 完整 trace 93.5 vs 只留对话文本 89.6
- Meta-Harness: 摘要 34.9 vs 原始 trace 50.0
- **注意：全部是‘文本 vs 文本’的对比**

形式轴

同样的信息，组织成树，比平文本好吗？

零证据

- 检索范围内，无人做过‘树 vs 平’的对照
- 三份报告一致标注：无证据
- **整份调研里最大的可做空白**

机会在形式轴——但它是一个待检验的假设，不是已成立的结论。

来源：方法 / 信号 / 输入存储三份报告综合结论；证据明细见方法报告 §8

为什么轮得到我们

结构先发

- trace-synthesis 已在产出统一逻辑树 (trace → LlmRequest → Tool) 。
- 下游要压平 , 随时可以 ; 反过来 , 丢了就没了。

规范先机

- OTel GenAI 已画好记忆的位置 :gen_ai.memory / skill / evaluation 。
- 全部 development 级 , 开源界零实现——对齐成本低、辨识度高。

数据缺口

- ‘同任务多次尝试’的 OTel 轨迹 : 不存在 (唯一 OTel 数据集每任务单条) 。
- 同实例 ‘一成一败’配对 , 单一组合下仅覆盖 12.2% 。

谁保有 ‘同实例一成一败’ 的配对关系 , 谁就握着选样的弹药。

来源 : 输入存储报告 §5(OTel 语义) 、 §9(数据集);12.2% 为单一组合同 instance 口径 (1,726 / 14,142 组)

下一步 · 最小实验

三条泳道，只换渲染

数据：Open-SWE-Traces 的同实例“一成一败”配对——单一组合下 1,726 组，取几十对即可启动。

A · span 树渲染

带编号、状态、耗时的树形文本（我们的假设）

B · 平铺全文

领域现状，作为基线

C · 掩码压缩

工具输出换占位符（成本对照）

同一抽取模型 · 温度 0 · 同一提示词框架——三臂之间只有渲染不同。

主指标 · 无效引用率

记忆引用了不存在的源 span = 幻觉；程序 100% 可判定，不需要 benchmark。

判据先写好

A 显著低于 B → 形式轴成立，进流水线；不成立则止损，负结果照样有价值。

协议 · PMSS 式

冻结产物、成对比较、精确检验；不碰端到端（噪声 2.2–6.0pp，端到端检出需上千配对）。

来源：“候选须指向源 span”（方法报告表 4-14，依据校验）；PMSS 协议（信号报告 §8）

收束

三句话带走

01 记忆生成长出了跨领域共识：六环节漏斗。 trace 是第一环——选样与依据，都压在它身上。

02 74 篇工作全在压平 trace: 丢信息有害，有证据；‘树更好’，零证据——空白恰好长在我们家。

03 记忆的验证极脆弱：自述不可信、噪声与增益同量级、闭环会膨胀。可验证性，要靠 trace 字段买单。

一条合格的记忆 = 内容 + 可信成败标签 + 可回指来源 + 适用条件 —— 四样，三样要 trace 出力。

讨论

留给大家的三个问题

Q1 我们的 span 树，离“记忆系统直接消费”，还缺哪些字段？

Q2 要不要在生成侧，显式保留“同实例一成一败”的配对关系？

Q3 三条泳道的最小实验，值不值得排进下个迭代？

深挖材料：memory-generation-reading-notes.md（本地共读笔记，13 场）· 三份报告在 27 机器 /data1/zwh/code/agent-trace-research/docs/memory-generation/research